

# Álgebra



**Universidad  
Internacional  
de Valencia**  
**Máster Universitario  
en Inteligencia Artificial**

**02MIAR | Matemáticas:**  
Matemáticas para la Inteligencia Artificial

**Profesor:**  
Amílcar J. Pérez A.

## Definición

*Un vector real  $v$  de dimensión  $n$  es una lista ordenada de  $n$  números reales:*


$$v = (v_1, v_2, \dots, v_n), \quad v_i \in \mathbb{R}.$$

*Se denota por  $\mathbb{R}^n$  el conjunto formado por todos los vectores de dimensión  $n$ . Por tanto, podemos escribir  $v \in \mathbb{R}^n$ .*

## Ejemplos

1.  $v = (1, -\frac{2}{3}) \in \mathbb{R}^2$ .
2.  $w = (\sqrt{2}, -1.2, \pi) \in \mathbb{R}^3$ .

Los vectores en  $\mathbb{R}^n$  se pueden representar gráficamente mediante un sistema de coordenadas  $n$  dimensional en caso de que  $n \leq 3$ .



## Definición

*Dados dos vectores  $v, w \in \mathbb{R}^n$ ,  $v = (v_1, v_2, \dots, v_n)$ ,  $w = (w_1, w_2, \dots, w_n)$ , definimos su suma componente a componente:*

$$v + w = (v_1 + w_1, v_2 + w_2, \dots, v_n + w_n).$$

## Definición

*Dado un número real  $\lambda$  (un escalar) y un vector  $v \in \mathbb{R}^n$ ,  $v = (v_1, v_2, \dots, v_n)$ , definimos el producto de un escalar por un vector así:*

$$\lambda \cdot v = \lambda v = (\lambda v_1, \lambda v_2, \dots, \lambda v_n).$$

Además de la longitud euclídea (noción usual longitud) es posible dar otras definiciones de la **norma** de un vector. Algunas normas importantes son:

- ▶ Norma euclídea (o norma 2):

$$\|v\| = \|v\|_2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}.$$

- ▶ Norma 1:

$$\|v\|_1 = \sum_{i=1}^n |v_i| = |v_1| + |v_2| + \cdots + |v_n|.$$

- ▶ Norma del máximo:

$$\|v\|_\infty = \max_{1 \leq i \leq n} |v_i|.$$

## Ejemplo

*Construimos un modelo computacional para predecir las temperaturas a partir de algunas variables de entrada (input). Supongamos que obtenemos un conjunto de  $n$  predicciones con el modelo considerado, almacenadas en un vector:*

$$\hat{v} = (\hat{v}_1, \hat{v}_2, \dots, \hat{v}_n) \in \mathbb{R}^n.$$

*Comparamos ahora el vector de predicciones,  $\hat{v}$ , con el vector de respuestas reales (observaciones),  $v = (v_1, \dots, v_n)$ . Una forma de hacerlo es utilizar alguna norma  $\|\cdot\|_*$  sobre la diferencia de los dos vectores:*

$$E = \frac{1}{n} \|\hat{v} - v\|_*$$

*Objetivo: encontrar un algoritmo que minimice  $E$ .*

El producto escalar entre dos vectores  $v, w \in \mathbb{R}^n$  se define como:

$$v \cdot w = \sum_{i=1}^n v_i w_i.$$

## Ejemplo

Sean  $v, w \in \mathbb{R}^3$ , con  $v = (2, -1, 0)$  y  $w = (-3, -2, 1)$ . Entonces

$$\begin{aligned} v \cdot w &= (2, -1, 0) \cdot (-3, -2, 1) \\ &= 2 \cdot (-3) + (-1) \cdot (-2) + 0 \cdot 1 = -6 + 2 + 0 = -4. \end{aligned}$$

## Definición


Sean  $u, v \in \mathbb{R}^n$ . Definimos la **proyección** de  $u$  sobre  $v$  como

$$\text{Proj}_v(u) = \frac{u \cdot v}{v \cdot v} v = \frac{u \cdot v}{\|v\|^2} v$$

## Definición

Sean  $u, v \in \mathbb{R}^n$ . Definimos la **ortogonal** de  $u$  sobre  $v$  como

$$\text{Ort}_v(u) = u - \text{Proj}_v(u)$$





## Definición

*Diremos que dos vectores  $u, v \in \mathbb{R}^n$  son **ortogonales** si  $u \cdot v = 0$ .*

La definición de ortogonalidad entre dos vectores se corresponde con la noción geométrica de perpendicularidad.

Más concretamente,

$$u \cdot v = \|u\| \|v\| \cos(\widehat{uv}),$$

donde  $\widehat{uv}$  es el ángulo que forman los vectores  $u$  y  $v$ .

De esta expresión se sigue que, siendo  $\hat{v} = v/\|v\|$  el vector unitario en la dirección de  $v$ :

$$\text{Proj}_v(u) = \|u\| \cos(\widehat{uv}) \hat{v}$$

## Propiedades

Para  $u, v, w \in \mathbb{R}^n$  y  $\lambda \in \mathbb{R}$ :

- ▶  $u + v = v + u.$
- ▶  $u \cdot v = v \cdot u.$
- ▶  $u \cdot (v + w) = u \cdot v + u \cdot w.$
- ▶  $(\lambda u) \cdot v = \lambda(u \cdot v).$
- ▶  $v \cdot v = \|v\|^2.$
- ▶  $u \cdot v = 0$  si y sólo si  $u$  y  $v$  son ortogonales.
- ▶  $v \cdot u = v \cdot \text{Proj}_v(u).$
- ▶  $\text{Ort}_v(u) \cdot v = 0$

## Definición

Dados  $v_1, v_2, \dots, v_k \in V$ , una **combinación lineal** de los  $k$  vectores anteriores es cualquier expresión de la forma

$$\lambda_1 v_1 + \lambda_2 v_2 + \dots + \lambda_k v_k,$$

con  $\lambda_j \in \mathbb{R}$  para  $j = 1, 2, \dots, k$

## Definición

Diremos que  $v_1, v_2, \dots, v_k \in V$  son **linealmente independientes** si se cumple que la ecuación

$$\lambda_1 v_1 + \lambda_2 v_2 + \dots + \lambda_k v_k = 0$$

tiene como única solución  $\lambda_1 = \lambda_2 = \dots = \lambda_k = 0$ . En caso contrario, se dice que éstos vectores son **linealmente dependientes**.

## Definición

Una **matriz** de tamaño  $m \times n$  sobre  $\mathbb{R}$  es un conjunto formado por  $m \cdot n$  números reales,  $a_{ij}$ ,  $1 \leq i \leq m$ ,  $1 \leq j \leq n$ , distribuidos en  $m$  filas y  $n$  columnas de la siguiente forma:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}.$$

Denotamos por  $\mathbb{R}^{m \times n}$  el conjunto de todas las matrices  $m \times n$  sobre  $\mathbb{R}$ . Una matriz  $A \in \mathbb{R}^{m \times n}$  es **cuadrada** si  $m = n$ , i.e., si tiene el mismo número de filas que de columnas.  $I_n = (\delta_{ij})$  es la matriz identidad  $n \times n$ .

Sean  $A, B \in \mathbb{R}^{m \times n}$ . Podemos definir la **suma** y la **resta**  $A \pm B$  como:

$$A \pm B = \begin{pmatrix} a_{11} \pm b_{11} & a_{12} \pm b_{12} & \cdots & a_{1n} \pm b_{1n} \\ a_{21} \pm b_{21} & a_{22} \pm b_{22} & \cdots & a_{2n} \pm b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} \pm b_{m1} & a_{m2} \pm b_{m2} & \cdots & a_{mn} \pm b_{mn} \end{pmatrix}$$

Asimismo, dado un escalar  $\lambda \in \mathbb{R}$ , definimos el **producto**  $\lambda \cdot A$  como

$$\lambda A = \begin{pmatrix} \lambda a_{11} & \lambda a_{12} & \cdots & \lambda a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & \lambda a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda a_{m1} & \lambda a_{m2} & \cdots & \lambda a_{mn} \end{pmatrix}$$

Por último, si  $A \in \mathbb{R}^{m \times \ell}$  y  $B \in \mathbb{R}^{\ell \times n}$ , entonces definimos el **producto matricial**  $A \cdot B \in \mathbb{R}^{m \times n}$  como

$$A \cdot B = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mn} \end{pmatrix}$$

donde  $c_{ij} = \sum_{k=1}^{\ell} a_{ik} b_{kj} = a_{i1} b_{1j} + a_{i2} b_{2j} + \cdots + a_{i\ell} b_{\ell j}$ .

## Nota

En general, el producto de matrices **NO** es conmutativo. Por ejemplo:

$$\begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 0 & 1 \\ -3 & 4 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ -6 & 7 \end{pmatrix}$$

$$\begin{pmatrix} 0 & 1 \\ -3 & 4 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} -1 & 2 \\ -7 & 8 \end{pmatrix}$$

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$ . Diremos que  $A$  es **invertible** o **regular** si existe  $B \in \mathbb{R}^{n \times n}$  tal que  $A \cdot B = B \cdot A = I_n$ . La matriz  $B$  recibe el nombre de **matriz inversa** y se denota por  $A^{-1}$ .

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$  una matriz cuadrada de la forma

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}.$$

Definimos el **determinante** de  $A$  de forma recurrente como sigue:

► Si  $n = 1$ ,  $\det(A) = a_{11}$ .

► Para  $n > 1$ :

$$\det(A) = \sum_{j=1}^n (-1)^{1+j} a_{1j} \det(A_{1j}),$$

donde  $A_{1j} \in \mathbb{R}^{(n-1) \times (n-1)}$  es la matriz resultante de eliminar en  $A$  la fila 1 y la columna  $j$ .



## Teorema

*El determinante de una matriz  $A$  puede calcularse de cualquiera de las siguientes formas:*

- ▶ *Desarrollo por la fila  $i$ ,  $1 \leq i \leq n$ :*

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}).$$

- ▶ *Desarrollo por la columna  $j$ ,  $1 \leq j \leq n$ :*

$$\det(A) = \sum_{i=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}).$$

*donde  $A_{ij} \in \mathbb{R}^{(n-1) \times (n-1)}$  es la matriz resultante de eliminar en  $A$  la fila  $i$  y la columna  $j$ .*

## Teorema

*Para todo par de matrices  $A, B \in \mathbb{R}^{n \times n}$ , se cumple*

$$\det(A \cdot B) = \det(A) \cdot \det(B).$$

## Teorema

*$A \in \mathbb{R}^{n \times n}$  es regular si y sólo si  $\det(A) \neq 0$ .*

## Definición

*El **rango** de una matriz  $A \in \mathbb{R}^{m \times n}$ , denotado por  $\text{rank}(A)$ , es el número máximo de **vectores columnas** de  $A$  linealmente independientes.*

## Teorema

*$A \in \mathbb{R}^{n \times n}$  es regular si y sólo si  $\text{rank}(A) = n$ .*

## Definición

Sea  $A \in \mathbb{R}^{m \times n}$ . La **traspuesta** de la matriz  $A$  se define como la matriz  $A^T \in \mathbb{R}^{n \times m}$  tal que  $A^T(i, j) = A(j, i)$ ,  $1 \leq i \leq n$ ,  $1 \leq j \leq m$ .

## Teorema

Sea  $A \in \mathbb{R}^{n \times n}$  regular. Entonces la inversa de  $A$ ,  $A^{-1}$ , viene dada por

$$A^{-1} = \frac{1}{\det(A)} \cdot \text{adj}(A),$$

donde  $\text{adj}(A)$  es la **matriz adjunta** de  $A$ , dada por  $\text{adj}(A) = C^T$ , con  $C(i, j) = (-1)^{i+j} |A_{ij}|$ ,  $1 \leq i, j \leq n$ , con  $|A_{ij}| = \det(A_{ij})$ .

## Definición

Diremos que una aplicación  $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$  es una **aplicación lineal** si  $\forall v, u \in \mathbb{R}^n$  y  $\forall \alpha, \beta \in \mathbb{R}$  se cumple

$$T(\alpha v + \beta u) = \alpha T(v) + \beta T(u).$$

## Ejemplos

1. La aplicación  $T : \mathbb{R}^3 \rightarrow \mathbb{R}^2$  dada por  $T(x, y, z) = (x + y, 2z - x)$  es lineal.
2. La aplicación  $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  dada por  $T(x, y) = (x, x^2 - y)$  no es lineal.
3. La aplicación  $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  dada por  $T(x, y) = (x - y, x + 1)$  no es lineal.

## Teorema

*Toda aplicación lineal  $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$  puede representarse matricialmente en forma única (en las bases estándar de  $\mathbb{R}^n$  y  $\mathbb{R}^m$ ). Concretamente, existe una única **matriz asociada**  $M_T = [T] \in \mathbb{R}^{m \times n}$  tal que, para todo  $v \in \mathbb{R}^n$  puede escribirse:*

$$T(v) = M_T v.$$

## Ejemplo

Sea  $f : \mathbb{R}^3 \rightarrow \mathbb{R}^4$  dada por

$$T(x, y, z) = \begin{pmatrix} x + y \\ y - z \\ 2x + y + z \\ 3z \end{pmatrix} \longrightarrow M_T = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \\ 2 & 1 & 1 \\ 0 & 0 & 3 \end{pmatrix}$$

**NOTA.** Sea  $\mathcal{B}_n = \{e_1, e_2, \dots, e_n\}$  la base canónica de  $\mathbb{R}^n$ , i.e.,  $e_i = (\delta_{ij})$ . Y sea  $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$  una transformación lineal. Entonces

$$[T] = (T(e_1) \mid T(e_2) \mid \dots \mid T(e_n)) \quad \text{donde los } T(e_j) \text{ son vectores columna}$$

Esto se ve considerando que todo vector  $v \in \mathbb{R}^n$  se escribe como  $v = c_1 e_1 + c_2 e_2 + \dots + c_n e_n = (c_1, c_2, \dots, c_n)^\top$  y que por la linealidad de  $T$  se tiene que

$$T(v) = c_1 T(e_1) + c_2 T(e_2) + \dots + c_n T(e_n) = \begin{pmatrix} T(e_1) & T(e_2) & \dots & T(e_n) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix}$$

## Teorema

Sea  $S : \mathbb{R}^n \rightarrow \mathbb{R}^\ell$  y  $T : \mathbb{R}^\ell \rightarrow \mathbb{R}^m$  aplicaciones lineales, con  $M_S$  y  $M_T$  las matrices asociadas respectivas. Entonces  $T \circ S : \mathbb{R}^n \rightarrow \mathbb{R}^m$  es una aplicación lineal, cuya matriz asociada viene dada por  $M_{T \circ S} = M_T M_S$ .

## Ejercicios

1. Comprueba que el teorema se cumple para los dos ejemplos anteriores.
2. Probar que  $T \circ S : \mathbb{R}^n \rightarrow \mathbb{R}^m$  es una aplicación lineal si  $T : \mathbb{R}^\ell \rightarrow \mathbb{R}^m$  y  $S : \mathbb{R}^n \rightarrow \mathbb{R}^\ell$  lo son.

**Notación:** La matriz asociada a  $T$ ,  $M_T$  también la denotamos por  $[T]$ .

## Ejemplo

*Un ejemplo clásico de aplicaciones lineales son las rotaciones. En el caso de  $\mathbb{R}^2$  vienen dadas por  $T_\theta : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  definidas como:*

$$T_\theta(x, y) = \begin{pmatrix} x \cos \theta - y \sin \theta \\ x \sin \theta + y \cos \theta \end{pmatrix} \longrightarrow [T_\theta] = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix},$$

*donde  $\theta$  representa el ángulo de rotación (en sentido antihorario). Por tanto, esta aplicación envía un vector  $(x, y) \in \mathbb{R}^2$  a su rotación en  $\theta$  radianes:  $(x \cos \theta - y \sin \theta, x \sin \theta + y \cos \theta)$ . Asimismo, y como ya sabemos, podemos expresar la transformación matricialmente:*

$$T_\theta(x, y) = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}.$$



## Ejemplo

*Por ejemplo, la rotación de  $30^\circ$  (o  $\pi/6$  rad) viene dada por:*

$$[T_{\pi/6}] = \begin{pmatrix} \cos(\pi/6) & -\sin(\pi/6) \\ \sin(\pi/6) & \cos(\pi/6) \end{pmatrix} = \begin{pmatrix} \sqrt{3}/2 & -1/2 \\ 1/2 & \sqrt{3}/2 \end{pmatrix}$$

*Por otra parte, la rotación de  $60^\circ$  (o  $\pi/3$  rad) viene dada por:*

$$[T_{\pi/3}] = \begin{pmatrix} \cos(\pi/3) & -\sin(\pi/3) \\ \sin(\pi/3) & \cos(\pi/3) \end{pmatrix} = \begin{pmatrix} 1/2 & -\sqrt{3}/2 \\ \sqrt{3}/2 & 1/2 \end{pmatrix}$$

*Por tanto, si componemos sendas rotaciones queda:*

$$[T_{\pi/3} \circ T_{\pi/6}] = \begin{pmatrix} \sqrt{3}/2 & -1/2 \\ 1/2 & \sqrt{3}/2 \end{pmatrix} \begin{pmatrix} 1/2 & -\sqrt{3}/2 \\ \sqrt{3}/2 & 1/2 \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} = [T_{\pi/2}]$$

## Ejemplo

*Cabe esperar que el resultado sea una rotación de  $90^\circ$  (o  $\pi/2$  rad) con respecto al original:*

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix}$$

*cumpléndose  $(x, y) \cdot (-y, x) = -xy + yx = 0$ , luego son ortogonales.*


## Ejercicio

*Utilizando las identidades trigonométricas que procedan, demuestra los siguientes enunciados:*

(a)  $\|T_\theta(v)\| = \|v\| \quad \forall v \in \mathbb{R}^2, \forall \theta \in \mathbb{R}.$

(b)  $T_\alpha \circ T_\beta = T_{\alpha+\beta} \quad \forall \alpha, \beta \in \mathbb{R}.$

Las matrices (y las aplicaciones lineales que representan) constituyen un elemento importante en la descripción de redes neuronales.




$$y_1 = f_1 (\omega_{11}x_1 + \omega_{12}x_2 + \omega_{13}x_3 + b_1),$$
$$y_2 = f_2 (\omega_{21}x_1 + \omega_{22}x_2 + \omega_{23}x_3 + b_2).$$

$$\Omega = \begin{pmatrix} \omega_{11} & \omega_{12} & \omega_{13} \\ \omega_{21} & \omega_{22} & \omega_{23} \end{pmatrix}, X = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}.$$

$$y_1 = f_1 (\Omega(1, \cdot)X + b_1),$$
$$y_2 = f_2 (\Omega(2, \cdot)X + b_2).$$

En general, para el caso de información de una capa de  $n$  neuronas ( $x_1, \dots, x_n$ ) que se transmite a otra capa de  $m$  neuronas ( $y_1, \dots, y_m$ ):



$$y_i = f_i \left( \sum_{j=1}^n \omega_{ij} x_j + b_i \right), 1 \leq i \leq m.$$

$$\Omega = \begin{pmatrix} \omega_{11} & \omega_{12} & \cdots & \omega_{1n} \\ \omega_{21} & \omega_{22} & \cdots & \omega_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \omega_{m1} & \omega_{m2} & \cdots & \omega_{mn} \end{pmatrix},$$

$$X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad \therefore y_i = f_i (\Omega(i, \cdot)X + b_i), 1 \leq i \leq m.$$

# ¡Muchas gracias!



**Universidad**  
Internacional  
de Valencia

**Contacto:**

[amilcar.perez@professor.universidadviu.com](mailto:amilcar.perez@professor.universidadviu.com)

