

Álgebra



**Universidad
Internacional
de Valencia**
**Máster Universitario
en Inteligencia Artificial**

02MIAR | Matemáticas:
Matemáticas para la Inteligencia Artificial

Profesor:
Amílcar J. Pérez A.

Definición

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cuadrada. Un **vector propio** o **autovector** $v \in \mathbb{R}^{n \times 1}$, $v \neq \vec{0}$, asociado a A es aquel que cumple que $\exists \lambda \in \mathbb{R}$ tal que $Av = \lambda v$. El valor λ recibe el nombre de **valor propio** o **autovalor** de A asociado al autovector v .

Ejemplo

Sea $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$. $\lambda_1 = 2$ y $\lambda_2 = -3$ son valores propios de A asociados a los vectores propios $v_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ y $v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, resp.:

$$\begin{aligned} Av_1 &= \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 2 \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 2v_1, \\ Av_2 &= \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -3 \\ -3 \end{pmatrix} = -3 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = -3v_2. \end{aligned}$$

- ▶ ¿Qué interés tiene conocer los autovalores y autovectores?
- ▶ Supongamos que, dada $A \in \mathbb{R}^{n \times n}$, conseguimos encontrar n autovectores linealmente independientes, $\{v_i\}_{i=1}^n$ (base de \mathbb{R}^n), asociados respectivamente a n autovalores, $\{\lambda_i\}_{i=1}^n$.
- ▶ Por definición, se tiene $Av_i = \lambda_i v_i$ para $1 \leq i \leq n$.
- ▶ Denotamos $P \in \mathbb{R}^{n \times n}$ a la matriz formada por los vectores propios dispuestos en columna y D a la matriz diagonal formada por los valores propios:

$$P = \begin{pmatrix} \uparrow & \uparrow & & \uparrow \\ v_1 & v_2 & \cdots & v_n \\ \downarrow & \downarrow & & \downarrow \end{pmatrix}, \quad D = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}.$$

- ▶ Entonces se cumple $AP = PD$. Equivalentemente: $P^{-1}AP = D$.
- ▶ $(AP)_{*j} = AP_{*j} = Av_j = \lambda_j v_j = PD_{*j} = (PD)_{*j}$

Ejemplo

Anteriormente vimos que los vectores propios de $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$ son $v_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ y $v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, asociados, respectivamente, a los autovalores $\lambda_1 = 2$ y $\lambda_2 = -3$. Definimos

$$P = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad D = \begin{pmatrix} 2 & 0 \\ 0 & -3 \end{pmatrix}$$

$$AP = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} \uparrow & \uparrow \\ Av_1 & Av_2 \\ \downarrow & \downarrow \end{pmatrix} = \begin{pmatrix} 4 & -3 \\ 2 & -3 \end{pmatrix}$$

$$PD = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & -3 \end{pmatrix} = \begin{pmatrix} \uparrow & \uparrow \\ \lambda_1 v_1 & \lambda_2 v_2 \\ \downarrow & \downarrow \end{pmatrix} = \begin{pmatrix} 4 & -3 \\ 2 & -3 \end{pmatrix}$$

Definición

Sea $A \in \mathbb{R}^{n \times n}$ una matriz cuadrada. Diremos que A es **diagonalizable** si $\exists P \in \mathbb{R}^{n \times n}$ regular y $D \in \mathbb{R}^{n \times n}$ diagonal tales que

$$P^{-1}AP = D.$$

- ▶ ¿Qué utilidad tiene diagonalizar una matriz?
- ▶ Cálculo del determinante:

$$\begin{aligned}\det(A) &= \det(PDP^{-1}) = \det(P) \det(D) \det(P^{-1}) \\ &= \det(P) \det(D) \frac{1}{\det(P)} = \det(D) = \prod_{i=1}^n \lambda_i.\end{aligned}$$

- ▶ Cálculo del rango:

$$\text{rank}(A) = |\{\lambda_i \mid \lambda_i \neq 0, 1 \leq i \leq n\}|.$$

- ▶ Cálculo de potencias matriciales.

Si $P^{-1}AP = D$, entonces multiplicando por P a la izquierda y P^{-1} a la derecha podemos obtener

$$A = PDP^{-1}.$$

- ▶ $A^2 = A \cdot A = (PDP^{-1})(PDP^{-1}) = PD(P^{-1}P)DP^{-1} = PD I_n DP^{-1} = P(D \cdot D)P^{-1} = PD^2P^{-1}.$
- ▶ $A^3 = A^2 \cdot A = (PD^2P^{-1})(PDP^{-1}) = PD^2(P^{-1}P)DP^{-1} = PD^2 I_n DP^{-1} = P(D^2D)P^{-1} = PD^3P^{-1}.$
- ▶ En general, se tiene

$$A^k = PD^kP^{-1}, \text{ donde } D^k = \begin{pmatrix} \lambda_1^k & 0 & \cdots & 0 \\ 0 & \lambda_2^k & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n^k \end{pmatrix}.$$

- ▶ Si $A \in \mathbb{R}^{n \times n}$, $\lambda \in \mathbb{R}$ es un valor propio de A y $v \in \mathbb{R}^{n \times 1}$ es un vector propio asociado a λ , entonces:

$$Av = \lambda v \Leftrightarrow Av - \lambda v = \vec{0} \Leftrightarrow Av - \lambda I_n v = \vec{0} \Leftrightarrow (A - \lambda I_n)v = \vec{0}.$$

- ▶ $(A - \lambda I_n)v = \vec{0}$ es un sistema de ecuaciones lineal **homogéneo** (términos independientes nulos). Por tanto, siempre es compatible:
 - ▶ Si $\det(A - \lambda I_n) \neq 0$, entonces es compatible determinado y su única solución es $v = \vec{0}$
 - ▶ Si $\det(A - \lambda I_n) = 0$, entonces es compatible indeterminado y tiene infinitas soluciones.
- ▶ Queremos encontrar vectores propios $v \neq \vec{0}$, luego imponemos $\det(A - \lambda I_n) = 0$ (**ecuación característica**). Las raíces de esta ecuación con incógnita λ son los valores propios.
- ▶ Para cada valor propio obtenido $\{\lambda_i\}_{i=1}^k$ se obtiene el máximo número de vectores linealmente independientes como que verifican $(A - \lambda_i I_n)v = \vec{0}$, $1 \leq i \leq k$.

Ejemplo

- ▶ Sea $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$.
- ▶ Ec. caract.: $\det(A - \lambda I_2) = 0 \rightarrow \det \begin{pmatrix} 7 - \lambda & -10 \\ 5 & -8 - \lambda \end{pmatrix} = 0 \rightarrow \lambda^2 + \lambda - 6 = 0 \rightarrow \lambda_1 = -3, \lambda_2 = 2$.
- ▶ *Vectores propios:*
 - ▶ $(A - \lambda_1 I_2)v = \vec{0} \rightarrow \begin{pmatrix} 10 & -10 \\ 5 & -5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} \alpha \\ \alpha \end{pmatrix}, \alpha \in \mathbb{R}.$
 $\alpha = 1 \rightarrow v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$
 - ▶ $(A - \lambda_2 I_2)v = \vec{0} \rightarrow \begin{pmatrix} 5 & -10 \\ 5 & -10 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2\alpha \\ \alpha \end{pmatrix}, \alpha \in \mathbb{R}.$
 $\alpha = 1 \rightarrow v_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$

Otras descomposiciones matriciales

- ▶ No todas las matrices son diagonalizables en \mathbb{R} .
- ▶ Si A es cuadrada y no diagonalizable \rightarrow **Forma canónica de Jordan**.
- ▶ Si A es rectangular \rightarrow **Factorización SVD** (*singular value decomposition*) \rightarrow PCA.
- ▶ Otras factorizaciones útiles:
 - ▶ Factorización LU (método de eliminación de Gauss).
 - ▶ Factorización de Cholesky (mínimos cuadrados, Montecarlo...).
 - ▶ Factorización QR (mínimos cuadrados).

Definición

Una matriz $A \in \mathbb{R}^{n \times n}$ es simétrica si $A^T = A$

Teorema

Si $A \in \mathbb{R}^{n \times n}$ es simétrica, entonces A es diagonalizable. Además, $\exists P \in \mathbb{R}^{n \times n}$ ortogonal ($P^T = P^{-1}$) tal que $P^T A P = D$.

Definición

Una matriz simétrica $A \in \mathbb{R}^{n \times n}$ es **definida positiva** (respectivamente **semidefinida positiva**) si $\forall v \in \mathbb{R}^{n \times 1}$, $v \neq \vec{0}$, $v^\top A v > 0$ (respectivamente $v^\top A v \geq 0$). Por otra parte, A es **(semi)definida negativa** si $-A$ es (semi)definida positiva.

Ejemplos

1. $I_n \in \mathbb{R}^{n \times n}$ es definida positiva $\forall n \in \mathbb{N}$. En efecto, dado $v \in \mathbb{R}^{n \times 1}$, $v \neq \vec{0}$,
 $v^\top I_n v = v^\top v = \|v\|_2^2 > 0$.
2. $0_n \in \mathbb{R}^{n \times n}$ es semidefinida positiva $\forall n \in \mathbb{N}$. En efecto, dado $v \in \mathbb{R}^{n \times 1}$, $v \neq \vec{0}$,
 $v^\top 0_n v = 0$.
3. $A = \begin{pmatrix} 1 & 2 \\ 2 & -1 \end{pmatrix} \in \mathbb{R}^{2 \times 2}$ no es (semi)definida positiva, pues, por ejemplo, tomando $v^\top = (0, 1)$, se tiene $v^\top A v = -1 < 0$. (Tampoco es (semi)definida negativa).

Definición

Sea $A \in \mathbb{R}^{n \times n}$ y $k \in \{1, 2, \dots, n\}$. El **menor principal dominante** de orden k asociado a A , al que denotaremos por A_k , es $A_k = \det(A(1:k, 1:k))$; es decir, el determinante de la submatriz formada por las primeras k filas y columnas.

Teorema

Sea $A \in \mathbb{R}^{n \times n}$ una matriz simétrica. Los enunciados siguientes son equivalentes:


- ▶ A es definida positiva (respectivamente, semidefinida positiva).
- ▶ $A_k > 0$, $\forall k \in \{1, 2, \dots, n\}$ (respectivamente, $A_k \geq 0$).
- ▶ $\forall \lambda \in \mathbb{R}$ valor propio de A , $\lambda > 0$ (respectivamente, $\lambda \geq 0$).

Definición

Un **tensor** es un objeto invariante con respecto a un cambio de coordenadas.

Ejemplos

1. Los **escalares** en \mathbb{R} son tensores.
2. Los **vectores** v de un espacio vectorial V son tensores.
3. Los elementos del conjunto V^* , formado por las aplicaciones lineales de la forma $V \rightarrow \mathbb{R}$, llamados **covectores**, son tensores.
4. Las aplicaciones lineales entre dos espacios vectoriales V y W , de la forma $V \rightarrow W$, tienen representación como tensores.
5. En consecuencia, las matrices de $\mathbb{R}^{m \times n}$ tienen representación como tensores.
6. Tensores métricos (ecuaciones de campo de Einstein).



► Vector: $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$


► Base $\mathcal{B} = \{e_1, e_2\}$, donde:

$$e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, e_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

► $v = 5e_1 + 4e_2$

► Coordenadas de v en la base \mathcal{B} :

$$\begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$



► Vector: $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$


► Base $\tilde{B} = \{\tilde{e}_1, \tilde{e}_2\}$, donde:

$$\tilde{e}_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

► $v = 2\tilde{e}_1 + 3\tilde{e}_2$

► Coordenadas de v en la base \tilde{B} :

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix}_{\tilde{B}}$$



► Vector: $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$


► Base $\tilde{\mathcal{B}} = \{\tilde{e}_1 = 2e_1, \tilde{e}_2 = 2e_2\}$,
donde:

$$\tilde{e}_1 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

► $v = 2.5\tilde{e}_1 + 2\tilde{e}_2$

► Coordenadas de v en la base $\tilde{\mathcal{B}}$:

$$\begin{bmatrix} 2.5 \\ 2 \end{bmatrix}_{\tilde{\mathcal{B}}} = \frac{1}{2} \begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$



► Vector: $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$

► Base $\tilde{\mathcal{B}} = \{\tilde{e}_1 = \frac{1}{2}e_1, \tilde{e}_2 = \frac{1}{2}e_1\}$,
donde:

$$\tilde{e}_1 = \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 0 \\ \frac{1}{2} \end{pmatrix}$$

► $v = 10\tilde{e}_1 + 8\tilde{e}_2$


► Coordenadas de v en la base $\tilde{\mathcal{B}}$:

$$\begin{bmatrix} 10 \\ 8 \end{bmatrix}_{\tilde{\mathcal{B}}} = 2 \begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$

- ▶ Diremos que una componente de un tensor es **contravariante** si ésta varía en proporción inversa con respecto a un cambio de coordenadas.
- ▶ **Ejemplo:** coordenadas de un vector con respecto a una base.
- ▶ Diremos que una componente de un tensor es **covariante** si ésta varía en proporción directa con respecto a un cambio de coordenadas.
- ▶ **Ejemplo:** coordenadas de un vector v formadas a partir de su producto escalar con los elementos de la base $\mathcal{B} = \{b_i\}_{i=1}^n$:

$$\begin{bmatrix} v \cdot b_1 \\ \vdots \\ v \cdot b_n \end{bmatrix}$$

- ▶ Los arrays multidimensionales son casos particulares de objetos que tienen representación de tensor.
- ▶ El **rango** de un tensor en forma de array representa las dimensiones espaciales en términos de la disposición de sus entradas.
 - ▶ Un escalar $x \in \mathbb{R}$ tiene rango 0.
 - ▶ Un vector $v \in \mathbb{R}^n$ tiene rango 1 (y dimensión n).
 - ▶ Una matriz $A \in \mathbb{R}^{n \times n}$ tiene rango 2 (y dimensión n).
 - ▶ Un array del tipo $A \in \mathbb{R}^{n \times n \times n}$ tiene rango 3 (y dimensión n).



- ▶ En general, $T_{j_1, \dots, j_q}^{i_1, \dots, i_p}$ es un tensor de tipo (p, q) (p componentes contravariantes y q componentes covariantes), con rango $p + q$.

Ejemplos

1. *Audio PCM Mono de 2 segundos, con frecuencia de muestreo de 48 kHz (48000 muestras por segundo).*
 - ▶ *Rango: 1.*
 - ▶ *Dimensión: 96000.*
2. *Audio PCM Stereo de 3 segundos, con frecuencia de muestreo 44.1 kHz (44100 muestras por segundo).*
 - ▶ *Rango: 2.*
 - ▶ *Dimensión: 2×132300 .*
3. *Imagen monocroma, con 600 píxeles de anchura y 800 píxeles de altura.*
 - ▶ *Rango: 2.*
 - ▶ *Dimensión: 600×800 .*

Ejemplos

4. *Imagen RGB, con 2000 píxeles de anchura y 1200 píxeles de altura.*
 - ▶ *Rango:* 3.
 - ▶ *Dimensión:* $3 \times 2000 \times 1200$.
5. *Vídeo monocromo de 1 minuto, a 30 fps (frames por segundo), con resolución 720p:*
 - ▶ *Rango:* 3.
 - ▶ *Dimensión:* $1800 \times 1280 \times 720$.
6. *Vídeo RGB de 40 segundos, a 60 fps (frames por segundo), con resolución 1080p:*
 - ▶ *Rango:* 4.
 - ▶ *Dimensión:* $2400 \times 3 \times 1920 \times 1080$.

¡Muchas gracias!



Universidad
Internacional
de Valencia

Contacto:

amilcar.perez@professor.universidadviu.com

